

Tabla de contenido

Módulo 3 – Hacer.....	2
Clase 4. Técnicas de prompting, multimodalidad y evaluación de respuestas.....	2
Resultados de aprendizaje observables.....	2
Parte 1.....	2
Descomposición, planificación y verificación.....	2
Chain-of-Thought prompting: evidencia, utilidad y límites.....	3
Roles, perspectivas y crítica estructurada.....	3
Parte 2.....	4
Multimodality: texto, imagen, audio y video.....	4
Evals y diseño de rúbricas.....	5
Temperature, variabilidad y reproducibilidad.....	6
Casos de uso pertinentes.....	6
Limitaciones, riesgos, controversias y errores frecuentes.....	6
Buenas prácticas.....	6
Demostración sugerida para el docente.....	7
Preguntas de reflexión o comprobación.....	7
Ideas clave para convertir en diapositivas.....	7
Fuentes utilizadas en esta clase.....	7
Bibliografía.....	8

Módulo 3 – Hacer

Clase 4. Técnicas de prompting, multimodalidad y evaluación de respuestas

Propósito. Profundizar en técnicas de interacción, comprender entradas y salidas multimodales y establecer un proceso riguroso para evaluar respuestas.

Resultados de aprendizaje observables

- Seleccionar una técnica de prompting según la tarea.
- Explicar alcances y límites del Chain-of-Thought.
- Distinguir capacidades multimodales de comprensión humana.
- Diseñar una rúbrica de evaluación con criterios y casos representativos.

Pregunta orientadora: ¿Cómo mejorar una respuesta sin confundir mayor elaboración con mayor exactitud?

Parte 1

Descomposición, planificación y verificación

Explicación intuitiva. Una tarea amplia suele mejorar cuando se divide en outputs verificables: primero extraer hechos, luego organizarlos, después redactar y finalmente revisar. La finalidad no es obligar al modelo a narrar pensamientos internos, sino reducir ambigüedad y crear puntos de control.

Planificar es útil cuando existen dependencias. Verificar exige volver a una fuente, ejecutar un cálculo o contrastar criterios; pedir “verifica tu respuesta” sin evidencia adicional puede repetir el mismo error con mayor seguridad.

Explicación técnica. La descomposición puede implementarse en un solo prompt con fases o como workflow con llamadas separadas y estados. La segunda opción permite validar schemas, registrar resultados y reintentar solo un paso. También reduce el riesgo de que errores tempranos queden ocultos en una respuesta final fluida.

Self-critique y reflection son técnicas estudiadas, pero su efectividad depende de modelo, tarea y acceso a señales externas. La verificación fuerte usa fuentes independientes, herramientas deterministas, constraints y tests.

Cuándo conviene y cuándo no. Conviene para informes extensos, extracción seguida de síntesis y tareas con formatos intermedios. No conviene fragmentar una solicitud trivial ni aumentar pasos sin mejorar un eval.

Los outputs intermedios con datos sensibles también requieren control de retención y acceso.

Ejemplo correcto. Extraer cifras con página, validar que cada cifra existe, organizar hallazgos y solo entonces redactar la síntesis ejecutiva.

Contraejemplo o error frecuente. Pedir una respuesta extensa y, al final, añadir “revisa que todo sea cierto” sin proporcionar fuentes ni una herramienta de comprobación.

Qué puede simplificar el docente. Puede mostrarse extraer → validar → sintetizar → revisar. Debe conservarse que verificación requiere una señal externa o un criterio independiente.

Chain-of-Thought prompting: evidencia, utilidad y límites

Explicación intuitiva. Chain-of-Thought (CoT) prompting solicita o induce pasos intermedios antes de una respuesta. Los trabajos de Wei et al. y Kojima et al. mostraron mejoras en ciertas tareas de razonamiento con modelos suficientemente grandes [14], [15]. La técnica no garantiza razonamiento correcto ni convierte el texto intermedio en una explicación fiel del mecanismo interno.

Para uso profesional es más útil pedir una justificación breve, supuestos, cálculos verificables o evidencia que solicitar una transcripción extensa del “pensamiento”. El objetivo es auditar el resultado, no antropomorfizar el proceso.

Explicación técnica. CoT puede funcionar como estructura de inference que facilita computaciones intermedias dentro de la secuencia generada. Su beneficio depende de task, model scale, ejemplos y decoding. Un rationale plausible puede acompañar una respuesta incorrecta, y un rationale no es necesariamente faithful respecto de las representaciones internas.

En sistemas actuales algunos modelos realizan internal reasoning que no se expone literalmente. Las recomendaciones de producto sobre pedir “piensa paso a paso” cambian por familia y versión. Por ello debe priorizarse la documentación vigente y medir outcomes, no asumir una técnica universal.

Alternativas más auditables son decomposition, tool use, program-of-thought para cálculos, retrieval con citas y output de supuestos/resultado. En decisiones sensibles puede ser preferible una explicación basada en evidencia y reglas, no un monólogo generado.

Cuándo conviene y cuándo no. Conviene CoT o descomposición en problemas multietapa donde los pasos ayudan al modelo y pueden verificarse. No conviene tratar el rationale como prueba de verdad, exigir exposición de reasoning privado ni usarlo para justificar automáticamente una decisión.

Cuando el cálculo es exacto, debe delegarse a una herramienta; cuando la evidencia es documental, deben citarse fragmentos.

Ejemplo correcto. Pedir “identifica supuestos, calcula con la herramienta y entrega resultado con unidades y comprobación”, evaluando el resultado contra casos conocidos.

Contraejemplo o error frecuente. Aceptar una explicación larga como evidencia de que el modelo razonó correctamente o de que su conclusión es justa.

Qué puede simplificar el docente. Puede decirse que los pasos intermedios ayudan en algunas tareas. Deben conservarse dependencia del modelo/tarea, falta de garantía de faithfulness y preferencia por evidencia verificable.

Roles, perspectivas y crítica estructurada

Explicación intuitiva. Asignar un role puede orientar vocabulario, audiencia y criterios: “actúa como editor técnico” sugiere revisar claridad y consistencia. No le concede credenciales, acceso ni responsabilidad reales. El valor surge cuando el role se acompaña de una tarea y una rúbrica, no de prestigio imaginario.

Pedir perspectivas ayuda a explorar trade-offs: finanzas observa costo, legal observa obligaciones, operaciones observa continuidad. Esas voces son lentes analíticos, no sustitutos de profesionales.

Explicación técnica. Role prompting condiciona el output mediante patrones asociados al role en training data. Puede mejorar tono y cobertura, pero también activar estereotipos o producir autoridad aparente. La crítica estructurada debe declarar criterios, fuentes y alcance.

Para reducir sycophancy, conviene pedir objeciones, evidencia contraria, supuestos y condiciones de cambio de opinión. Aun así, varias respuestas del mismo modelo no son fuentes independientes.

Cuándo conviene y cuándo no. Conviene para adaptar comunicación y ampliar perspectivas. No conviene pedir “actúa como abogado/médico” para eludir revisión profesional o afirmar que el output tiene esa autoridad.

La crítica funciona mejor con una rúbrica que con “sé crítico”.

Ejemplo correcto. “Como editor de informes ejecutivos, revisa claridad, evidencia y coherencia usando esta rúbrica; no añadas hechos; marca afirmaciones sin fuente.”

Contraejemplo o error frecuente. “Eres el mejor experto mundial; garantiza que esta estrategia funcionará”.

Qué puede simplificar el docente. Puede definirse role como lente y no como credencial. Debe conservarse el riesgo de autoridad aparente y la necesidad de criterios.

Parte 2

Multimodality: texto, imagen, audio y video

Explicación intuitiva. Un modelo multimodal recibe o produce más de una modalidad: texto, imagen, audio o video. No significa que perciba como una persona. Cada modalidad se convierte en representaciones numéricas y se integra de acuerdo con la arquitectura. La utilidad surge cuando la tarea exige relacionarlas, como explicar un gráfico con su nota metodológica.

Los errores cambian por modalidad. OCR puede confundir dígitos; una imagen recortada elimina contexto; audio ruidoso altera transcripción; video muestreado puede omitir un instante. Una respuesta verbal convincente puede ocultar un error visual básico.

Explicación técnica. Las arquitecturas suelen usar encoders específicos o tokenización de patches/frames/audio y proyectan sus representaciones a un espacio que el Transformer puede procesar. Los detalles varían. Resolution, sampling, compression y context budget afectan qué información llega al modelo [17].

La evaluación debe separar perception —qué elementos detectó—, grounding —a qué región o segmento se refiere— y reasoning —qué conclusión derivó—. Mezclar las tres etapas dificulta diagnosticar el fallo.

Metadata y provenance importan. Un modelo puede analizar pixels, pero no verificar por sí solo autoría, fecha o edición. Para documentos, OCR debe contrastarse con la página original, especialmente en cifras y tablas.

Cuándo conviene y cuándo no. Conviene para describir diagramas, extraer tablas, resumir reuniones autorizadas o relacionar imagen y texto. No conviene usarlo como única lectura de evidencia crítica, identificación de personas o diagnóstico especializado.

Datos biométricos, voces, reuniones e imágenes pueden ser personales o confidenciales; se requiere autorización, minimización y retención apropiada.

Ejemplo correcto. Extraer una tabla de una imagen, marcar celdas de baja confianza y revisar cada cifra contra la página original antes de pasarla a una hoja de cálculo.

Contraejemplo o error frecuente. Subir una reunión confidencial a una herramienta pública o asumir que una descripción de imagen prueba la autenticidad del archivo.

Qué puede simplificar el docente. Puede decirse que varias modalidades se convierten en representaciones. Deben conservarse los errores específicos y la separación perception-grounding-reasoning.

Evals y diseño de rúbricas

Explicación intuitiva. Una rúbrica convierte “buena respuesta” en dimensiones observables. Para un resumen pueden ser fidelidad, cobertura, claridad, adecuación a audiencia y citas. Cada dimensión debe tener niveles con ejemplos, porque dos revisores pueden interpretar de manera distinta una palabra como “completo”.

Evaluar prompts es comparar sistemas completos bajo los mismos casos, no elegir la respuesta favorita de una conversación.

Explicación técnica. El diseño incluye unit of evaluation, sampling, criteria, scale, anchors y critical failures. Algunas dimensiones admiten métricas automáticas; otras requieren revisión humana. Inter-rater agreement ayuda a detectar rúbricas ambiguas.

Model-based graders pueden escalar evaluación, pero deben calibrarse con humanos, controlar position bias y no recibir información que el sistema evaluado no tuvo. La evaluación debe incluir abstención, adversarial inputs y casos de información ausente [16].

A/B tests sin un conjunto estable pueden confundir variabilidad de sampling con mejora real. Deben fijarse versiones, repetir casos cuando corresponda y analizar error por segmento.

Cuándo conviene y cuándo no. Conviene una rúbrica para seleccionar prompts/modelos y revisar outputs repetibles. No conviene usar un promedio para ocultar una falla crítica ni cambiar criterios después de ver resultados.

En tareas de alto impacto, ciertos errores deben ser disqualifying aunque la puntuación total sea alta.

Ejemplo correcto. Puntuar fidelidad y cobertura por separado, con ejemplos de 1, 3 y 5; registrar citas inventadas como falla crítica.

Contraejemplo o error frecuente. Preguntar a un LLM cuál de sus dos respuestas es mejor y aceptar el veredicto como único eval.

Qué puede simplificar el docente. Puede mostrarse criterios + niveles + ejemplos. Deben conservarse casos representativos, baseline, calibración y análisis de failure modes.

Temperature, variabilidad y reproducibilidad

Explicación intuitiva. Temperature ajusta cuánta diversidad se permite al elegir continuaciones. Es comparable a decidir si se escoge casi siempre la opción con mayor puntuación o se exploran alternativas. No mide creatividad como rasgo humano y no controla verdad.

Dos respuestas distintas pueden ser aceptables en ideación; en extracción de campos, la variación suele ser un problema. La configuración debe responder a la tarea.

Explicación técnica. Temperature reescala logits antes de softmax. Junto con top-p/top-k y seed, cuando existe, influye en sampling. Reproducibilidad también depende de versión del modelo, infraestructura, contexto, herramientas y actualizaciones no anunciadas.

Temperature cero suele aproximar greedy decoding, pero no garantiza bitwise determinism ni factualidad. Para outputs estructurados se necesitan schemas y validación, no solo decoding más conservador.

Cuándo conviene y cuándo no. Conviene baja variabilidad en clasificación, extracción y formatos; mayor exploración en alternativas creativas, seguida de selección. No conviene comparar prompts si cambian simultáneamente modelo, contexto y sampling.

Registrar configuración y fecha ayuda a interpretar resultados.

Ejemplo correcto. Generar varias propuestas con mayor diversidad, luego evaluarlas con una rúbrica estable y fuentes.

Contraejemplo o error frecuente. Afirmer que temperature 0 elimina hallucination o que temperature alta produce ideas originales garantizadas.

Qué puede simplificar el docente. Puede usarse “conservador vs. exploratorio”. Debe conservarse que afecta sampling, no conocimiento ni verificación.

Casos de uso pertinentes

- Analizar texto, imagen y audio con validación por modalidad.
- Crear variantes de redacción y evaluarlas con rúbrica.
- Extraer tablas de una imagen y contrastarlas con el original.

Limitaciones, riesgos, controversias y errores frecuentes

- Confundir explicación extensa con evidencia.
- Errores específicos de modalidad invisibles a una rúbrica genérica.
- Cambios de versión que invalidan comparaciones.
- Uso de datos sensibles en audio, imagen o video.

Buenas prácticas

- Separar generación y validación externa.
- Evaluar por dimensión y definir fallas críticas.
- Anonimizar o usar datos sintéticos en pruebas.

- Registrar fecha, modelo, prompt, fuentes y configuración.

Demostración sugerida para el docente

Analizar la misma pieza de información como texto y como captura de pantalla; mostrar errores posibles de OCR. Luego comparar dos respuestas con una rúbrica definida antes de verlas.

Preguntas de reflexión o comprobación

- ¿Qué hace verificable un razonamiento?
- ¿Qué error es propio de una modalidad?
- ¿Qué dimensión no debe compensarse con buen estilo?
- ¿Cuándo la variabilidad es deseable?

Ideas clave para convertir en diapositivas

- Descomponer → producir → verificar.
- Chain-of-Thought: evidencia situada y límites.
- Multimodal no significa infalible.
- Rúbrica por dimensiones.
- Temperature: sampling, no verdad.

Fuentes utilizadas en esta clase

Referencias principales: [5], [14], [15], [16], [17], [43]. Las características de productos citadas deben verificarse de nuevo antes de impartir la sesión, porque pueden cambiar con versiones, planes y región.

Bibliografía

La bibliografía completa se encuentra en el siguiente archivo:

<https://evinracher.github.io/curso-sinergia/recursos/fundamentos-teoricos.pdf>